Università degli Studi di
Cassino e del Lazio Meridionale

Dipartimento di Ingegneria Elettrica
e dell'Informazione "Maurizio Scarano"

Corso di Laurea in Ingegneria Informatica
e delle Telecomunicazioni

Analisi del Ragionamento negli LLM tramite Entropia Condizionale

Relatore:
Prof. Alessandro Bria

Candidato:
Pietro D'Agosto

ANNO ACCADEMICO 2024/2025

Abstract

Nonostante i *Large Language Models* (LLM) abbiano dimostrato notevoli capacità come risolutori generici, il loro approccio alla risoluzione di problemi complessi rimane assimilabile a un processo intuitivo (Sistema 1). Il ragionamento deliberato (Sistema 2) richiede l'esplorazione di molteplici percorsi alternativi, un processo che necessita di euristiche che lo indirizzino verso la soluzione corretta. Basandosi su uno studio oracolo di riferimento, che correla la riduzione dell'entropia condizionale all'accuratezza della risposta, questa tesi adotta la medesima metrica per valutare l'utilità dei passi di ragionamento. Nello specifico, lo studio propone una metrica di divergenza, calcolata tra le traiettorie entropiche medie dei cluster di tracce, ipotizzandone una correlazione con la correttezza della risposta. Inoltre, si approfondisce la dinamica dell'incertezza a livello di singola traccia, esaminando la corrispondenza tra le variazioni entropiche e i passi intermedi di ragionamento. I risultati sperimentali non supportano l'ipotesi che la divergenza sia un *proxy* diretto della correttezza, evidenziandone invece il legame con la frequenza di generazione della risposta. L'analisi sulle singole tracce rivela inoltre che il ragionamento corretto non segue un decremento monotono dell'incertezza, presentando fasi divergenti che fungono da "impalcatura" necessaria alla risoluzione.

Indice

1 Introduzione **1**

2 Fondamenti Teorici **3**
2.1 Modelli linguistici di grandi dimensioni (LLM) 3
2.1.1 Formalizzazione del modello 3
2.1.2 Generazione autoregressiva 5
2.1.3 Teacher forcing 6
2.2 Ragionamento negli LLM 6
2.3 Chain of Thought 7
2.4 Entropia condizionale 8
2.5 Studio oracolo di riferimento 9
2.5.1 Metodologia 9
2.5.2 Risultati 10

3 Metodologia di Analisi **12**
3.1 Dataset MATH 12
3.2 Setup e Ambiente 13
3.3 Generazione delle tracce 14
3.4 Calcolo delle traiettorie entropiche 15
3.5 Elaborazione delle traiettorie 16

4 Valutazione Sperimentale **18**
4.1 Analisi entropica per cluster 18
4.1.1 Obiettivo 18
4.1.2 Elaborazione dati e Criteri 19
4.1.3 Risultati e Discussione 20
4.2 Approfondimento sulle singole tracce 27
4.2.1 Obiettivo 27
4.2.2 Elaborazione dati e Criteri 27
4.2.3 Risultati e Discussione 28

5 Conclusioni **35**

A Analisi statistica **37**

B Splines cubiche **39**

Bibliografia **40**

Capitolo 1

Introduzione

Nonostante i notevoli risultati conseguiti dai modelli linguistici di grandi dimensioni (LLM) nella generazione e comprensione del testo, il loro approccio alla risoluzione di problemi complessi è assimilabile a quello del "Sistema 1". Secondo la teoria del doppio processo [1], la cognizione umana opera attraverso due modalità distinte: il Sistema 1, rapido ed intuitivo, impiegato per la maggior parte dei compiti di routine, e il Sistema 2, lento e deliberato, necessario per la scomposizione sistematica del problema, la verifica dei passaggi logici e l'eventuale correzione degli errori.

Recenti studi hanno dimostrato come, oltre al *training-time scaling* (l'addestramento su una mole crescente di dati), l'accuratezza dei modelli possa essere significativamente incrementata tramite tecniche di *test-time scaling*, le quali allocano maggiori risorse computazionali durante la fase di inferenza. In questo ambito, una tecnica degna di nota è la *Chain-of-Thought* (CoT), che simula l'approccio deliberato del Sistema 2, esplicitando i passaggi intermedi del ragionamento durante l'inferenza. L'evoluzione in questo campo è stata rapida: numerosi framework hanno iniziato a strutturare la ricerca della soluzione tramite grafi o alberi, impiegando algoritmi quali *Breadth First Search*, *Depth First Search* o *Monte Carlo Tree Search*. Parallelamente, modelli come DeepSeek-R1 o OpenAI-o1 sono stati addestrati specificamente su tracce di ragionamento esplicite per favorire una fase di riflessione antecedente la generazione della risposta finale.

Tuttavia, una ricerca efficiente tra i vari percorsi risolutivi necessita di un'euristica efficace che indirizzi il modello verso quelli più probabili, evitando il dispendio di risorse computazionali su percorsi non ottimali. Nella letteratura attuale, molti framework adottano diverse euristiche: alcune basate su metriche interne (come perplessità o confidenza), altre su modelli esterni (*Process Reward Models* o verificatori). Poiché l'uso di modelli esterni richiede spesso un addestramento specifico per dominio, e le metriche interne citate non mostrano una correlazione diretta con la correttezza della risposta, emerge la necessità di individuare una metrica interna al modello e agnostica al dominio, in grado di fungere da euristica valida per guidare il ragionamento.

Il presente lavoro di tesi trae origine dall'approfondimento di tale tematica, con l'obiettivo di individuare una metrica interna correlata all'utilità del ragionamento. A tal fine, si è preso in esame lo studio di Guo et al. (2025), definito 'oracolo' poiché basato sulla conoscenza a priori della risposta corretta (*ground truth*). Tale lavoro analizza le tracce di ragionamento utilizzando l'entropia condizionale, una misura dell'incertezza media del modello nella generazione di una risposta dato un contesto. Sebbene lo studio di riferimento si focalizzi sul dataset MATH, l'entropia rappresenta una grandezza probabilistica intrinseca al processo generativo del modello; tale natura la rende una metrica potenzialmente agnostica al dominio di ragionamento. Disponendo della risposta corretta (*ground truth*), i risultati dello studio oracolo evidenziano come le tracce corrette presentino mediamente un andamento decrescente delle traiettorie entropiche, mentre quelle errate mostrino un andamento meno ripido, piatto o crescente.

A partire da tali premesse, questa tesi approfondisce l'analisi della metrica nell'ottica di una possibile applicazione pratica, soffermandosi successivamente sull'osservazione delle variazioni entropiche all'interno delle singole tracce. La prima analisi verifica l'ipotesi secondo cui, la divergenza tra le traiettorie entropiche dei cluster di tracce sia correlata alla correttezza della risposta, sulla base dei trend emersi dallo studio oracolo. I risultati sperimentali smentiscono parzialmente tale ipotesi, rilevando una correlazione con la risposta più frequente piuttosto che con quella corretta. La seconda analisi costituisce un approfondimento sulle singole tracce: esaminando la corrispondenza tra passaggi intermedi e variazioni entropiche, si evidenzia come i passaggi divergenti non siano superflui, ma fungano da "impalcatura" necessaria per abilitare percorsi risolutivi altrimenti non percorribili.

La tesi è strutturata nei seguenti capitoli:

- Capitolo 2: Riporta le nozioni teoriche necessarie alla comprensione dei capitoli successivi, tra cui lo studio oracolo di riferimento e la metrica su cui si basa l'analisi.
- Capitolo 3: Riporta le metodologie di analisi utilizzate, descrivendo l'intero processo di elaborazione dei dati, dai problemi matematici del dataset alle traiettorie entropiche oggetto di studio.
- Capitolo 4: Riporta la valutazione sperimentale, presentando entrambe le analisi citate, con relativi risultati e interpretazioni.

Il codice sorgente e i dati sperimentali sono disponibili al seguente *repository*:

`https://github.com/Pit-windows/llm-reasoning-entropy`.

Capitolo 2

Fondamenti Teorici

In questo capitolo vengono riportate le nozioni teoriche necessarie alla comprensione del lavoro svolto. La struttura del capitolo ripercorre il percorso metodologico adottato: si parte dalla descrizione dello strumento, i modelli linguistici di grandi dimensioni (LLM), grazie ai quali è possibile generare il ragionamento esplicito tramite la metodologia *Chain-of-Thought* (CoT). Tale processo è oggetto dello studio oracolo di riferimento di Guo et al. (2025) [2], che ne ha indagato le dinamiche mediante l'entropia condizionale, la metrica che costituisce il fondamento dell'analisi di questa tesi.

2.1 Modelli linguistici di grandi dimensioni (LLM)

I modelli linguistici di grandi dimensioni (*Large Language Models*) rappresentano una classe di modelli linguistici basati sull'architettura *Transformer*, caratterizzati da un numero di parametri nell'ordine delle centinaia di miliardi e addestrati su *corpora* testuali di grandi dimensioni.

Questi modelli dimostrano notevoli capacità nella comprensione del linguaggio naturale e nella risoluzione di compiti complessi attraverso la generazione di testo. Una peculiarità distintiva degli LLM risiede nel fatto che, superata una soglia di parametri e dati (*scaling laws*), essi manifestano "capacità emergenti", quali il ragionamento o la capacità di seguire istruzioni, che non si osservano nei modelli di scala inferiore e che non sono state esplicitamente programmate [3, Sec. 2.1].

In virtù di tali proprietà, la letteratura scientifica definisce gli LLM come "risolutori di compiti generici" (*general-purpose task solvers*) [3, Sec. 1].

2.1.1 Formalizzazione del modello

Nel contesto di questa tesi, l'LLM viene astratto come una funzione matematica complessa f_θ, dove θ denota l'insieme dei parametri del modello che elabora le informazioni testuali. L'analisi prescinde dai dettagli architetturali interni dei modelli per focalizzarsi sulla trasformazione tra l'input e l'output.

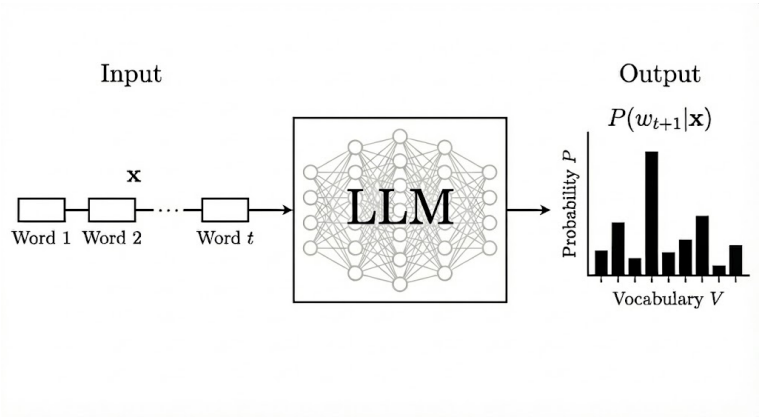

Figura 2.1: LLM come *black box* per l'elaborazione di input e generazione di output.

Elaborazione dell'input. L'input del modello è costituito da una sequenza di testo in linguaggio naturale, spesso strutturata sotto forma di *prompt*, il quale può includere la descrizione del compito, i dati di input e informazioni contestuali. Il vocabolario $\mathcal{V}$ di un LLM non opera a livello di parole intere, approccio che risulterebbe computazionalmente oneroso e inefficace nella gestione di termini non presenti nel vocabolario (*out-of-vocabulary*). Si adottano, invece, algoritmi di *subword tokenization* (come *Byte-Pair Encoding* o *WordPiece*), i quali decompongono una stringa di testo S in una sequenza discreta di unità elementari denominate *token* [3, Sec. 4.1.2].

Possiamo denotare il processo di tokenizzazione con una funzione τ:

$$\tau(S) = \mathbf{x} = (x_1, x_2, \ldots, x_N)$$

Poiché la rete neurale elabora esclusivamente dati numerici, a ogni token nel vocabolario $\mathcal{V}$ è associato univocamente un indice intero $j \in \{1, \ldots, |\mathcal{V}|\}$, dove $|\mathcal{V}|$ rappresenta la dimensione del vocabolario stesso. L'input effettivo diviene pertanto una sequenza di indici interi (IDs):

$$\mathbf{x}_{1:N} = [id(x_1), \ldots, id(x_N)]$$

In ultimo, ogni indice viene mappato al rispettivo vettore di *embedding* $\mathbf{e}_i \in \mathbb{R}^{d_e}$, selezionato dalla matrice di *embedding* $\mathbf{E} \in \mathbb{R}^{|V| \times d_e}$, dove d_e indica la dimensione dello spazio di embedding del modello [3, Sec. 2.1]. Si ottiene così la matrice di input $\mathbf{X}$ che il modello elaborerà:

$$\mathbf{X} = [\mathbf{e}_1, \ldots, \mathbf{e}_N] \in \mathbb{R}^{N \times d_e}$$

Elaborazione dell'output. Il modello restituisce in uscita un vettore di *logits* $\mathbf{l} \in \mathbb{R}^{|\mathcal{V}|}$, in cui ogni componente l_j esprime il punteggio non normalizzato per il j-esimo token del vocabolario. La probabilità P di selezionare un generico token x_j al passo i, condizionata dal contesto precedente $\mathbf{x}_{<i}$, è ottenuta applicando la

funzione Softmax al vettore dei *logits*, eventualmente modulata da un parametro di temperatura t [3, Eq. 10]:

$$P(x_j|\mathbf{x}_{<i}) = \frac{\exp(l_j/t)}{\sum_{k=1}^{|\mathcal{V}|} \exp(l_k/t)} \tag{2.1}$$

L'insieme di tali probabilità calcolate per ogni $x_j \in \mathcal{V}$ costituisce la distribuzione di probabilità del token i-esimo. A partire da questa distribuzione, una specifica strategia di decodifica (come la *Greedy Search* o il *Sampling*) determina la selezione del token effettivo di output [3, Sec. 4.2.4].

2.1.2 Generazione autoregressiva

Il meccanismo generativo degli LLM si fonda sul paradigma del *Language Modeling*, il cui obiettivo fondamentale è "modellare la probabilità generativa di sequenze di parole, al fine di predire le probabilità dei token futuri (o mancanti)" [3, Sec. 1]. Durante l'elaborazione, "ogni token di input può prestare attenzione esclusivamente ai token passati e a se stesso"; tale meccanismo, noto come *masked attention*, impedisce al modello l'accesso alle informazioni future preservando la coerenza temporale della sequenza [3, Sec. 4.2.1].

La generazione della sequenza di output avviene in modalità *token-by-token* attraverso un processo autoregressivo iterativo. Dati i token precedenti $x_{<i}$, il modello calcola la probabilità condizionata su tutto il vocabolario $\mathcal{V}$. Da questa distribuzione viene selezionato il token predetto, il quale viene successivamente concatenato al contesto esistente per costituire l'input della predizione successiva.

La selezione del token avviene secondo strategie di decodifica che influenzano le caratteristiche del testo generato. La *Greedy Search* rappresenta l'approccio deterministico, selezionando dalla distribuzione il token con probabilità più alta; al contrario, le tecniche basate sul *Sampling* introducono un elemento stocastico, selezionando "casualmente il token successivo in base alla distribuzione di probabilità, per migliorare la diversità durante la generazione" [3, Sec. 4.2.4].

Sebbene tale meccanismo sia di natura statistica, i modelli sviluppano una capacità predittiva superiore alla mera sintassi. Come osservato da Ilya Sutskever (co-sviluppatore di AlexNet e co-fondatore di OpenAI), *"Ciò che la rete neurale apprende è una rappresentazione del processo che ha prodotto il testo... questo testo è in realtà una proiezione del mondo"* [3, Sec. 2.2]. Tale concetto è esemplificato intuitivamente attraverso l'analogia di un romanzo giallo: per predire accuratamente il nome del colpevole nell'ultima pagina, non è sufficiente la conoscenza delle regole linguistiche; è necessario aver "compreso la trama, i personaggi e gli indizi" disseminati nel testo. Pertanto, "più si è accurati nel predire la parola successiva... maggiore è la risoluzione che si ottiene in questo processo" di modellazione della realtà [3, Sec. 4.2.5].

2.1.3 Teacher forcing

Il *teacher forcing* è una tecnica standard per l'addestramento degli LLM, fondata sul principio di massima verosimiglianza [4]. Essa prevede che, ad ogni passo temporale t, il modello riceva in input il token di *ground truth* y_{t-1}, indipendentemente dalla predizione formulata al passo precedente. Formalmente, questo approccio permette di scomporre la log-verosimiglianza della sequenza target Y, dato il contesto C, come somma delle log-probabilità condizionate:

$$\log P(Y \mid C) = \sum_{t=1}^{T} \log P(y_t \mid y_{<t}, C)$$

Sebbene tale tecnica sia convenzionalmente utilizzata in fase di *training* per l'aggiornamento dei parametri θ, l'approccio è applicabile anche in fase di inferenza.

Ciò consente di vincolare il modello a percorrere la traiettoria di una specifica risposta candidata Y, inibendo la generazione libera e permettendo così di analizzare puntualmente le distribuzioni di probabilità stimate per ciascun token di Y. In tale configurazione, il modello non produce nuova informazione, bensì rivela la compatibilità della risposta imposta rispetto al contesto fornito.

2.2 Ragionamento negli LLM

Il ragionamento è definito come la capacità di "rispondere a domande, che coinvolgono processi complessi e a più fasi, con passaggi intermedi" [5, Sec. 1]. Questa facoltà trascende la risposta immediata dettata da una "intuizione" veloce e diretta, configurandosi invece come un "processo di pensiero" deliberato. Tale processo va oltre la semplice generazione sequenziale, introducendo "fasi cognitive gerarchiche, come la pianificazione strategica, la verifica introspettiva e il raffinamento iterativo"; è un processo di "deliberazione interna" ed esplorazione caratterizzato dalla "formulazione di nuove ipotesi e la ricerca di percorsi risolutivi alternativi". La complessità del problema viene così suddivisa in sottoproblemi intermedi, la cui risoluzione consente di formulare la risposta finale.

Sistema 1 e Sistema 2. La distinzione cognitiva fondamentale si basa sulla teoria del doppio sistema (*Dual-system theory*), la quale suggerisce che "la cognizione umana opera attraverso due modalità: il Sistema 1, che è veloce, automatico e intuitivo, permettendo decisioni rapide con uno sforzo minimo, e il Sistema 2, che è più lento, più analitico ma computazionalmente più costoso" [5, Sec. 1]. Sebbene il Sistema 1 sia efficiente per i compiti di routine, "è incline a bias cognitivi, specialmente in situazioni complesse o incerte, portando a errori di giudizio" [5, Sec. 1]. Al contrario, il Sistema 2 mitiga questi bias poiché "si basa sul ragionamento logico e sul pensiero sistematico, risultando in decisioni più accurate e razionali" [5, Sec. 1]. Pertanto, l'obiettivo nell'attuale ricerca sul ragionamento negli LLM è quello di "raffinare la transizione dal veloce e intuitivo Sistema 1 al ragionamento più lento e deliberato del Sistema 2" [5, Sec. 1].

LLM come Sistema 1. Nonostante i loro successi, gli attuali LLM "operano in modo simile al ragionamento del Sistema 1, basandosi su un processo decisionale veloce e guidato da euristiche" [5, Sec. 1]. Questi modelli eccellono nel fornire risposte rapide ("*fast decision-making*") , ma mancano della profondità per il ragionamento complesso, in quanto non hanno ancora internalizzato pienamente l'analisi passo-passo caratteristica del vero pensiero del Sistema 2 [5, Sec. 1]. Pertanto, una prima fase della ricerca sul ragionamento negli LLM si è concentrata principalmente sul "potenziare gli LLM pre-addestrati con algoritmi di ragionamento esterni, senza alterare i parametri del modello" [5, Sec. 3.3]. In questo contesto, approcci esterni come il *Tree of Thoughts* o il *Reasoning via Planning* hanno utilizzato *Breadth-First Search*, *Depth-First Search* e *Monte Carlo Tree Search* per "simulare processi di ragionamento simili a quelli umani" [5, Sec. 3.3], rappresentando gli stati intermedi del ragionamento come nodi di un albero o di un grafo.

2.3 Chain of Thought

Il *Chain-of-Thought* (CoT) è una strategia di *prompting* che abilita i modelli linguistici a generare una serie di passaggi di ragionamento intermedi in linguaggio naturale, propedeutici alla formulazione dell'output finale [6, Sec. 1]. Tale approccio trasforma l'inferenza da una mappatura diretta e implicita ($Problema \rightarrow Risposta$) a un processo esplicito e sequenziale, fondato sulla decomposizione di problemi complessi in sottoproblemi gestibili. Il processo è dunque reso scalabile rispetto alla complessità del problema stesso [6, Sec. 2].

Questa capacità, che emerge con l'aumentare della scala del modello [6, Sec. 3.2], può essere elicitata attraverso due modalità principali: l'inclusione nel *prompt* di esempi dimostrativi (*Few-Shot CoT*) o l'impiego di istruzioni agnostiche rispetto al task, come "Let's think step by step" (*Zero-Shot CoT*) [7, Sec. 1].

Il CoT consente ai modelli di svolgere ragionamenti complessi trasferendo informazioni dalla conoscenza latente del modello (i parametri) al contesto esplicito, rendendole disponibili per i passaggi successivi [6, Abstract, Sec. 2]. Studi meccanicistici confermano che, durante la generazione della CoT, avviene una transizione tangibile nelle rappresentazioni interne del modello: le informazioni contestuali sostituiscono progressivamente le associazioni statistiche (prior) memorizzate durante il pre-addestramento [8, Abstract, Sec. 6.1].

È stato dimostrato che il modello utilizza molteplici percorsi interni paralleli (circuiti neurali) per raccogliere le informazioni necessarie alla risposta direttamente dal contesto generato [8, Sec. 6.3, Sec. 7]. Di conseguenza, la generazione della traccia modifica lo stato interno del modello, spostando il focus dal "prior di pre-addestramento" al "prior in-contesto" [8, Sec. 7]. In sintesi, il modello si ancora alla traccia di ragionamento che esso stesso ha prodotto per derivare la risposta finale; ciò rende la CoT una valida *finestra interpretativa* sul comportamento del modello, offrendo un riscontro osservabile del ragionamento che ha condotto a una determinata risposta [6, Sec. 2].

2.4 Entropia condizionale

Al fine di fornire una definizione formale di entropia condizionale, è opportuno introdurre preliminarmente i concetti di sorpresa ed entropia per una variabile aleatoria discreta X, caratterizzata da una funzione di massa di probabilità $p(x)$.

Sorpresa. Dato un evento $x \in \mathcal{X}$, si definisce la sorpresa (o auto-informazione) come il logaritmo del reciproco della sua probabilità [9]:

$$I(x) = \log\left(\frac{1}{p(x)}\right) = -\log p(x)$$

Intuitivamente, la proporzionalità inversa tra sorpresa e probabilità riflette il fatto che non si è sorpresi di assistere a un evento quasi deterministico, mentre lo si è quando accade qualcosa di poco probabile. Formalmente, il verificarsi di un evento ad alta probabilità apporta un contenuto informativo pressoché nullo, mentre l'accadere di un evento poco probabile è associato a un elevato contenuto informativo; la grandezza misura il contenuto informativo associato all'esito x.

Entropia. L'entropia di Shannon $H(X)$ corrisponde al valore atteso della sorpresa. Essa quantifica, pertanto, la tendenza media del processo aleatorio X a generare sorpresa ad ogni suo avvenimento. La definizione formale è la seguente [9]:

$$H(X) = \mathbb{E}[I(X)] = \sum_{x \in \mathcal{X}} p(x) \log\left(\frac{1}{p(x)}\right)$$

Shannon dimostra che $H(X)$ rappresenta il limite inferiore della lunghezza media del codice necessario per rappresentare senza perdita di informazione un risultato di X [10]. In quest'ottica, l'entropia assume il significato di "costo medio" informativo da sostenere per descrivere il processo aleatorio.

Entropia condizionale. Si consideri ora una seconda variabile aleatoria Y. L'entropia condizionale $H(X|Y)$ quantifica l'incertezza residua su X data la conoscenza di Y [9]. Tale grandezza non è definita rispetto a una singola realizzazione y, bensì come la somma delle entropie di X calcolate per ogni possibile esito di Y, ciascuna ponderata per la probabilità $p(y)$ che tale esito si verifichi. L'espressione formale è:

$$H(X|Y) = \sum_{y \in \mathcal{Y}} p(y) \cdot H(X|Y = y)$$

Espandendo il termine $H(X|Y = y)$, otteniamo la definizione basata sulla probabilità congiunta [9]:

$$H(X|Y) = -\sum_{y \in \mathcal{Y}} \sum_{x \in \mathcal{X}} p(x, y) \log p(x|y) \tag{2.2}$$

Tale valore rappresenta il costo medio residuo necessario alla descrizione di X data l'osservazione dell'evento Y.

2.5 Studio oracolo di riferimento

Lo studio oracolo proposto da Guo et al. (2025) [2] origina dalla ricerca di un metodo per stimare l'utilità di un singolo passo di ragionamento, durante la fase di generazione [2, Sec. 1]. Tale esigenza nasce dall'assenza, in letteratura, di indagini sistematiche che analizzino l'evoluzione dell'incertezza del modello durante lo sviluppo del ragionamento, così come la correlazione tra tale traiettoria e la correttezza della risposta finale [2, Sec. 1].

Fondamento teorico. La domanda di ricerca centrale è: "Dato un problema X ed una traccia di ragionamento Z, quanta informazione aggiuntiva fornisce Z sulla risposta corretta Y rispetto a quella già contenuta in X?"

Viene così formalizzato il concetto di utilità della traccia Z (sezione 2.3) tramite l'informazione mutua condizionale [2, Sec. 3]:

$$I(Y; Z|X) = H(Y|X) - H(Y|X, Z)$$

dove $H(\cdot)$ indica l'entropia (2.2).

Un elevato valore di informazione mutua condizionale $I(Y; Z|X)$ segnala che il ragionamento ha ridotto significativamente lo spazio delle possibili risposte; al contrario, valori minori indicano che la traccia non fornisce informazioni utili [2, Sec. 3].

2.5.1 Metodologia

Lo studio analizza il ragionamento matematico basandosi sul dataset MATH, utilizzando il modello `Qwen2.5-32B` per generare le tracce di ragionamento su diversi problemi [2, Sec. 4]. Per ogni dominio matematico, le tracce vengono divise in due cluster ("corrette" ed "errate") confrontando la risposta generata con risposta corretta (*ground truth*).

La quantificazione dell'incertezza è affidata a un modello separato detto "ispettore", ovvero `Qwen3-8B` [2, Sec. 4].

Si consideri una sequenza target $Y = (y_1, \ldots, y_{|Y|})$ e un contesto $C = [X; Z_{\leq k}]$, composto dal problema iniziale X e dalla traccia di ragionamento Z fino al passo k. Tramite *teacher forcing* (Sezione 2.1.3), per ogni posizione t, dato l'input $[C; y_{<t}]$, il modello stima una distribuzione di probabilità p_t sull'intero vocabolario $\mathcal{V}$, assegnando a ogni token v il valore:

$$p_t(v) = \Pr(v \mid C, y_{<t})$$

L'entropia condizionale del singolo token è calcolata su questa distribuzione di probabilità:

$$H_t = -\sum_{v \in \mathcal{V}} p_t(v) \log p_t(v)$$

Poiché Y è una sequenza, definiamo l'entropia condizionale dell'intera sequenza come la media delle entropie dei singoli token che la compongono:

$$H(Y \mid C) = \frac{1}{|Y|} \sum_{t=1}^{|Y|} H_t = \mathbb{E}_{t \in \{1,\ldots,|Y|\}}[H_t] \tag{2.3}$$

Tale metrica quantifica l'incertezza media del modello durante la generazione della risposta Y, dato il contesto C. Iterando per ogni passo k di ogni traccia si ottiene la rispettiva traiettoria entropica.

Tuttavia, poiché le tracce di ragionamento presentano un numero di passi variabile, non si può ottenere una traiettoria media per cluster in modo diretto. Lo studio applica un ricampionamento, tramite interpolazione con *splines cubiche* (appendice B), su un asse con un numero fisso di passi: ciò consente di allineare tutte le curve su un dominio comune preservandone la forma e consentendo il calcolo della traiettoria entropica media (figura 2.2) [2, Sec. 4]. Ogni dominio matematico sarà dunque caratterizzato dalle traiettorie entropiche medie dei due cluster.

2.5.2 Risultati

I dati mostrano che le tracce corrette producono un costante guadagno di informazione, come evidenziato per il dominio *Intermediate Algebra* nella figura 2.2: la loro traiettoria entropica media è nettamente decrescente [2, Sec. 5]. Al contrario, le tracce errate mostrano traiettorie meno ripide, piatte o crescenti, specialmente nei sottodomini dove l'accuratezza del modello è bassa, e risultano mediamente più lunghe [2, Sec. 5]. Il confronto con le tracce redatte da umani evidenzia inoltre una differenza strategica: gli umani riducono l'entropia drasticamente nelle fasi iniziali ("inquadrando" subito il problema), mentre il modello riduce l'incertezza in modo più graduale [2, Sec. 5]. Gli autori precisano infine che, configurandosi come uno studio oracolo dipendente da *ground truth*, l'impiego in contesti reali di questi segnali entropici, richiede strategie attuabili in assenza della risposta corretta nota a priori [2, Sec. 5, Sec. 6].

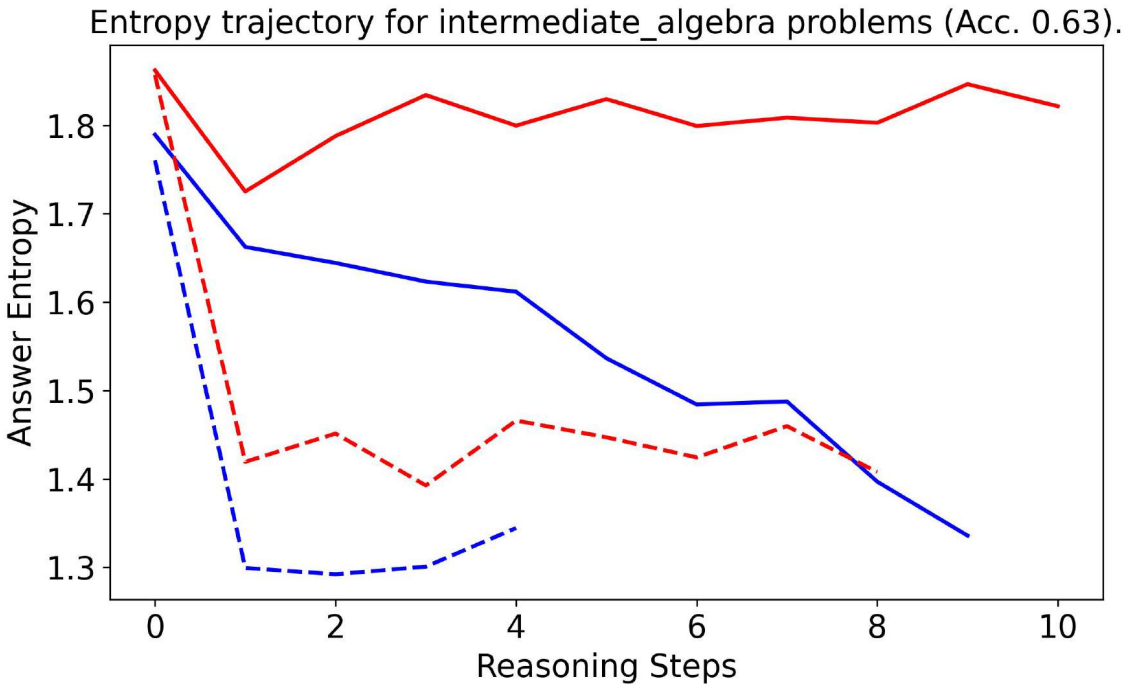

Figura 2.2: Traiettorie entropiche medie delle tracce corrette — e di quelle errate —. Le curve tratteggiate rappresentano le soluzioni redatte da umani. Fonte: Guo et al. (2025) [2].

Capitolo 3

Metodologia di Analisi

Il presente capitolo descrive nel dettaglio la metodologia adottata per la generazione e l'elaborazione dei dati. Il processo ha inizio con la selezione di specifici problemi dal dataset MATH e prosegue con la loro risoluzione, mediante la generazione di molteplici tracce di ragionamento. Successivamente, tali tracce vengono convertite in traiettorie entropiche, la cui analisi costituisce il nucleo del lavoro proposto in questa tesi.

3.1 Dataset MATH

Il dataset MATH [11] rappresenta un benchmark standard per la valutazione delle competenze di *problem solving* matematico degli LLM. Il dataset comprende sette domini matematici, tra cui Algebra, Teoria dei Numeri e Geometria, classificando i problemi su una scala di cinque livelli di difficoltà crescente. Ciascuna voce del dataset include il testo del problema, una soluzione passo-passo redatta da umani e la risposta finale corretta, definita come *ground truth* [11, Sec. 3.1].

Criteri di Selezione. La selezione dei problemi dal dataset si basa sulle evidenze emerse dallo studio oracolo di riferimento (sezione 2.5). Nello specifico, si è scelto di focalizzare l'analisi sul dominio *Intermediate Algebra*. Tale scelta è motivata dal fatto che questo dominio presenta la minore accuratezza rispetto al modello utilizzato (63%), condizione ideale per lo studio dell'ipotesi descritta nell'analisi entropica per cluster (sezione 4.1). Il campione selezionato comprende 9 problemi, ripartiti in 4 problemi di Livello 4 e 5 problemi di Livello 5, corrispondente alla difficoltà massima.

3.2 Setup e Ambiente

L'ambiente software utilizzato in questa tesi è `Modal Notebooks` [12], una piattaforma di *computing* in cloud, che fornisce un'interfaccia interattiva per l'esecuzione del codice in blocchi (celle) e la visualizzazione dei risultati. La scelta di tale ambiente è stata dettata dalla necessità di accedere a risorse hardware ad alte prestazioni; nello specifico, per la generazione delle tracce ed il calcolo delle traiettorie entropiche, è stata impiegata una GPU `Nvidia A100 80GB`. L'intera *pipeline*, riportata nella figura 3.1, è stata implementata in linguaggio Python, avvalendosi di librerie standard per il *deep learning* quali *transformers* e *PyTorch*.

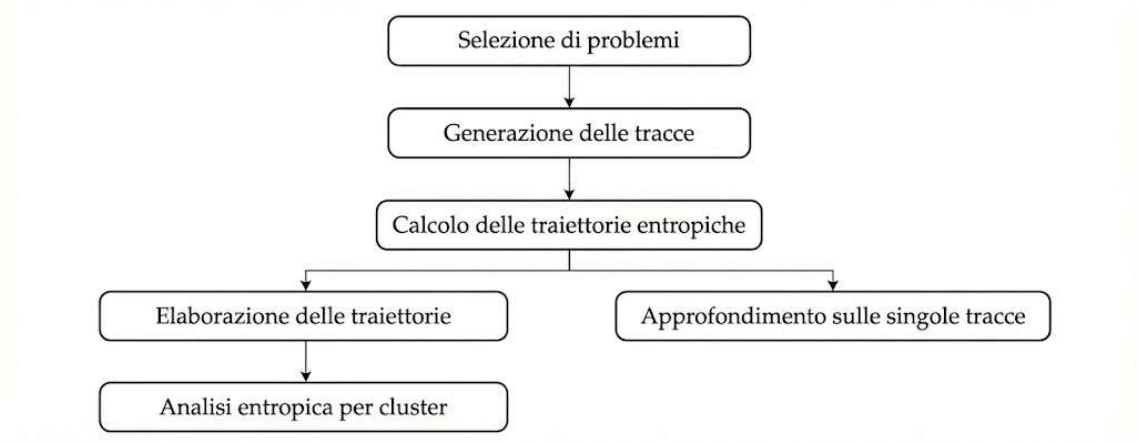

Figura 3.1: *Pipeline* del processo di generazione ed elaborazione dei dati.

3.3 Generazione delle tracce

Per ciascuno dei problemi selezionati, sono state generate 64 tracce di ragionamento. Il modello generatore impiegato è `Qwen2.5-32B`, con pesi in precisione `bfloat16`. L'output è stato generato utilizzando la *pipeline* di `text-generation` della libreria *transformers*, la cui configurazione dei parametri è la seguente:

- `max_new_tokens=1536`
- `do_sample=True`
- `temperature=0.8`
- `top_p=0.95`

Il prompt di generazione delle tracce, riportato nel Listing 1, implementa la tecnica *Zero-Shot CoT* (sezione 2.3) mediante l'istruzione esplicita "Let's think step by step". Al fine di ottenere un output strutturato, sono state imposte regole di formattazione.

```

PRE_PROMPT = r'''Let's solve the following math problem step by step.

**Required Formatting:**
* Provide a step-by-step solution.
* Each step **must** begin on a new line and be formatted *exactly* as `Step N:` (e.g., `Step 1:`, `Step 2:`, etc.).
* The final section **must** begin on a new line and be formatted *exactly* as `Final Answer:`.
* The final mathematical answer **must** be enclosed in the `\boxed{}` command.

**Problem:**\n
'''
prompt = PRE_PROMPT + problem

```

Listing 1: Prompt di generazione delle tracce.

Parsing e pre-elaborazione. Per la successiva elaborazione delle tracce, si è reso necessario un processo di conversione delle stringhe generate in liste strutturate. Il *parsing* è stato realizzato mediante la libreria *re*, per l'esecuzione di espressioni regolari (*Regular Expressions*), applicando pattern *regex* basati sui marcatori 'Step [numero]' e 'Final Answer', per segmentare il testo ed estrarre il contenuto dei singoli passaggi. La struttura dati risultante concatena il testo del problema al primo passo di ragionamento; l'ultimo elemento della lista corrisponde alla risposta finale, estratta dal `\boxed{}` e normalizzata tramite la rimozione degli spazi superflui.

3.4 Calcolo delle traiettorie entropiche

Le tracce di ragionamento strutturate vengono convertite in traiettorie entropiche, adottando la metodologia descritta nella sezione 2.5.1. Come modello ispettore è stato impiegato `DeepSeek-R1-0528-Qwen3-8B`, una variante di `Qwen3-8B` ottimizzata tramite *knowledge distillation* dal modello `DeepSeek-R1-0528` per compiti di ragionamento complesso. La scelta di questo modello specifico risponde all'esigenza di bilanciare l'efficienza computazionale con la capacità di analisi: condividendo il medesimo *tokenizer* del modello generatore, esso permette un'analisi granulare del ragionamento con un costo computazionale ridotto.

Al fine di ottimizzare le risorse e sfruttare appieno le capacità di calcolo parallelo della GPU, l'elaborazione avviene in modalità *batch*. Inoltre, la *pipeline* è stata concepita per calcolare le traiettorie entropiche una sola volta, memorizzando i risultati per le successive fasi di analisi. Per ciascun passo della traccia, viene dapprima costruito un contesto concatenando tutti i passi precedenti. Su tale contesto, si procede al calcolo dell'entropia condizionale della risposta finale, impiegando la tecnica del *teacher forcing* (sezione 2.1.3).

Il funzionamento dettagliato dell'algoritmo è illustrato nel Listing 2. La funzione accetta in input un *batch* di contesti, ai quali viene concatenata la risposta scelta. Il modello esegue un unico *forward pass* sull'intero batch, restituendo un tensore di dimensioni $[B, L, V]$, dove B è la dimensione del batch, L la lunghezza dell'intera sequenza in token e V la dimensione del vocabolario. Successivamente, i token relativi alla risposta finale vengono isolati, ottenendo i *logits* condizionati dal contesto, sui quali si calcola l'entropia. L'entropia condizionale a livello di sequenza è quindi ottenuta effettuando la media delle entropie dei singoli token costituenti la risposta scelta (sezione 2.5.1). Questo procedimento viene reiterato per ogni passo della traccia, ottenendo la corrispondente traiettoria entropica.

```python
import torch
from torch.distributions import Categorical

def calculate_conditional_entropy_batched(contexts, response, model, tokenizer):
    response_ids = tokenizer.encode(response, add_special_tokens=False)
    response_len = len(response_ids)

    if response_len == 0:
        return [0.0] * len(contexts)

    inputs = [f"{c} {response}" for c in contexts]
    batch = tokenizer(inputs, return_tensors='pt', padding=True).to(model.device)

    with torch.no_grad():
        outputs = model(**batch)
        logits = outputs.logits

    relevant_logits = logits[:, -(response_len + 1) : -1]

    token_entropies = Categorical(logits=relevant_logits).entropy()
    mean_entropy = token_entropies.mean(dim=1)

    return mean_entropy.tolist()

```

Listing 2: Calcolo dell'entropia condizionale.

3.5 Elaborazione delle traiettorie

Questa fase prevede il *clustering* delle tracce secondo le specifiche della sezione 4.1.2, validando l'appartenenza al cluster tramite *string matching* esatto sulla risposta finale. Tuttavia, le tracce di ragionamento all'interno di uno stesso cluster presentano lunghezze variabili. Per poter estrarre una traiettoria entropica rappresentativa, è necessario allinearle su un dominio comune. A tale scopo è stato implementato un algoritmo di ricampionamento, che utilizza le *splines cubiche* (appendice B), formalizzato nell'Algoritmo 1.

Una volta allineate le traiettorie entropiche del cluster, si procede al calcolo della media puntuale dei valori, ottenendo la traiettoria media del cluster. Contestualmente, per ogni punto del dominio normalizzato, viene calcolato l'errore standard. Tale misura è fondamentale per quantificare l'incertezza associata ad ogni punto della traiettoria media stimata.

Algoritmo 1 Ricampionamento delle traiettorie

Input: Insieme di traiettorie C

Output: Insieme di traiettorie ricampionate R

1. Calcolo della lunghezza media

$L_{\text{sum}} \leftarrow 0$
for all $c \in C$ **do**
    $L_{\text{sum}} \leftarrow L_{\text{sum}} + \text{Length}(c)$
end for
$L_{\text{avg}} \leftarrow \text{Round}(L_{\text{sum}}/|C|)$

2. Definizione del dominio comune

$X_{\text{target}} \leftarrow \text{Linspace}(\text{start} = 0, \text{end} = 1, \text{steps} = L_{\text{avg}})$
$R \leftarrow \emptyset$

3. & 4. Interpolazione e Ricampionamento

for all $c \in C$ **do**
    $n \leftarrow \text{Length}(c)$
    $X_{\text{source}} \leftarrow \text{Linspace}(\text{start} = 0, \text{end} = 1, \text{steps} = n)$
    $S \leftarrow \text{CubicSpline}(x = X_{\text{source}}, y = c)$
    $c_{\text{new}} \leftarrow \text{Evaluate}(S, \text{at} = X_{\text{target}})$
    $R.\text{append}(c_{\text{new}})$
end for

return R

Capitolo 4

Valutazione Sperimentale

In questo capitolo vengono presentati i risultati dell'indagine sperimentale sull'efficacia dell'entropia condizionale nell'analisi del ragionamento.

Il percorso sperimentale muove dalle evidenze emerse dallo studio oracolo di riferimento [2], ricercando inizialmente una metodologia che ne consentisse un'applicazione pratica in assenza di *ground truth*, per poi scendere nel dettaglio delle dinamiche di ragionamento utilizzando la metrica a scopo interpretativo.

La prima sezione (4.1) restringe il campo di indagine al singolo problema analizzando le traiettorie entropiche medie dei cluster, mentre la seconda sezione (4.2) lo restringe ulteriormente esaminando il contenuto semantico delle singole tracce di ragionamento.

4.1 Analisi entropica per cluster

L'analisi mira a tradurre le evidenze dello studio oracolo [2] in un'applicazione pratica, studiando la correlazione tra entropia condizionale e utilità del ragionamento in assenza di *ground truth*. A tale scopo, è necessario condurre un'analisi a livello di singolo problema, approfondendo i risultati per sottodominio riportati dallo studio oracolo.

4.1.1 Obiettivo

Lo studio oracolo di riferimento (sezione 2.5) ha evidenziato che, specialmente in sottodomini matematici a bassa accuratezza quali *Intermediate Algebra* e *Precalculus*, l'andamento entropico dei cluster mostra una separazione netta misurato rispetto alla risposta corretta $Y_{corretta}$. Nello specifico, mentre le tracce la cui risposta finale è $Y_{corretta}$ esibiscono un andamento decrescente dell'entropia condizionale, le tracce con risposta finale diversa tendono a mantenere un'entropia costante o crescente (Sezione 2.5.2). Questa dinamica crea una forte divergenza tra i due cluster di tracce.

Sebbene tale comportamento sia noto e documentato rispetto alla risposta corretta, lo studio non estende l'analisi all'andamento rispetto alle risposte errate. Da questa evidenza deriva l'ipotesi secondo la quale la forte divergenza osservata rispetto a $Y_{corretta}$ ne costituisca una peculiarità distintiva. Se tale assunzione fosse vera, formalizzando una metrica quantitativa della divergenza si potrebbe stimare la correttezza di una generica risposta Y, con possibilità di stabilire un criterio di *ranking* su un insieme di risposte generate.

4.1.2 Elaborazione dati e Criteri

Per verificare l'ipotesi, l'enunciato teorico è stato formalizzato come segue:

Sia S l'insieme di N tracce di ragionamento (CoT) che risolvono il problema matematico X.

Sia $V = \{Y_1, Y_2, \ldots, Y_k\}$ il vocabolario delle k risposte finali uniche derivate da S.

Per ogni $Y_i \in V$ si partizioni S in due cluster:

- Cluster Y_i : sottoinsieme di tracce la cui risposta finale è Y_i
- Cluster $\neg Y_i$: sottoinsieme di tracce la cui risposta finale è diversa da Y_i

Per ogni candidato Y_i, si analizzano le traiettorie dell'entropia media dei cluster, ottenute secondo la metodologia definita nello studio oracolo (Sezione 3.5); su di esse si calcola la media delle differenze puntuali (Mean Signed Difference) assumendo come riferimento la traiettoria del cluster $\neg Y_i$.

Osservazione. Il numero di tracce dei singoli cluster non è uniforme, ma varia in funzione delle occorrenze della risposta target Y_i, presentando spesso sbilanciamenti. Di conseguenza, l'affidabilità statistica della traiettoria dell'entropia media calcolata dipende strettamente dalla dimensione campionaria (N) di ciascun cluster. A tal fine, nei grafici sono riportate le bande di incertezza relative ad ogni punto della traiettoria media, calcolate applicando l'errore standard $s_{\bar{x}}$, moltiplicato per il fattore di copertura $k = 2$ (intervallo di confidenza al 95,4%), al valore medio puntuale. È necessario notare che, per i cluster con $N < 30$, l'uso del fattore $k = 2$ comporta una sottostima dell'ampiezza dell'intervallo, la quale diviene più marcata al diminuire del numero di tracce nel cluster (appendice A).

La metrica scelta per quantificare la divergenza è la media delle differenze puntuali (*Mean Signed Difference*), poiché oltre a quantificarne l'intensità fornisce un'informazione diretta tramite il segno. Assumendo come riferimento la traiettoria del cluster $\neg Y_i$, una divergenza con segno positivo indica che l'entropia del cluster $\neg Y_i$ risulta mediamente superiore a quella del cluster Y_i. In linea con l'ipotesi formulata, il comportamento atteso è che per la risposta corretta $\Delta(Y_i)$ assuma un valore significativamente positivo.

Definito T come la lunghezza minima in passi di ragionamento (*steps*) tra le due traiettorie medie, la metrica $\Delta(Y_i)$ è calcolata nel seguente modo:

$$\Delta(Y_i) = \frac{1}{T}\sum_{t=1}^{T}\left(H_t(\neg Y_i) - H_t(Y_i)\right) \tag{4.1}$$

dove $H_t(\cdot)$ rappresenta l'entropia condizionale media al passo t (Sezione 2.4).

Assumendo pertanto $\Delta(Y_i)$ come *score* di correttezza, il criterio di selezione identifica la stima della risposta corretta $\hat{Y}$ come quella che massimizza il Δ sull'intero vocabolario V:

$$\hat{Y} = \arg\max_{Y_i \in V} \Delta(Y_i) \tag{4.2}$$

4.1.3 Risultati e Discussione

L'analisi dei dati è riassunta quantitativamente nella Tabella 4.1 e qualitativamente nelle Figure 4.1-4.3, che riportano le traiettorie entropiche medie con relative bande di incertezza, e nella Figura 4.4, dove sono raffigurate le distanze che determinano la metrica di divergenza. Da tali evidenze emergono le seguenti osservazioni.

La Tabella 4.1 riporta i valori di divergenza $\Delta(Y_i)$ (Eq. 4.1) calcolati per la risposta corretta $Y_{corretta}$ e per le prime due risposte errate, ordinate per numero di occorrenze ($Y_{errata1}$, $Y_{errata2}$). La notazione grafica adottata è la seguente: i valori <u>sottolineati</u> sono relativi alla risposta con il maggior numero di occorrenze nel vocabolario V, mentre i valori in **grassetto** sono relativi alla stima $\hat{Y}$ selezionata mediante il criterio (4.2).

Tabella 4.1: Analisi della divergenza Δ

Problema	$\boldsymbol{Y}_{\textbf{corretta}}$	$\boldsymbol{Y}_{\textbf{errata 1}}$	$\boldsymbol{Y}_{\textbf{errata 2}}$
Int. Algebra (Liv. 4)			
#1	<u>0.0213</u>	**0.0766**	0.0231
#2	-0.0190	<u>**0.2801**</u>	0.0456
#3	<u>0.0940</u>	**0.1915**	-0.1429
#4	<u>**0.1016**</u>	0.0439	0.0715
Int. Algebra (Liv. 5)			
#1	-0.0032	<u>**0.3126**</u>	-0.1728
#2	0.0552	<u>**0.1444**</u>	-0.0482
#3	<u>**0.1596**</u>	-0.2461	-1.0386
#4	0.0380	<u>**0.1500**</u>	-0.0488
#5	<u>-0.0191</u>	**0.0988**	0.0843

L'analisi non supporta l'ipotesi che la forte divergenza entropica sia distintiva della risposta corretta. Il tasso di accuratezza nella stima di $\hat{Y}$ (Eq. 4.2) è pari al 22% (2 problemi su 9), ciò conferma empiricamente che la divergenza non può fungere da *proxy* per la correttezza di una risposta $Y_i \in V$. Dall'analisi dei grafici in figura 4.1 si nota una sostanziale sovrapposizione delle traiettorie dei cluster e delle relative bande di incertezza; tale evidenza le rende statisticamente indistinguibili nei passi iniziali, in contrapposizione con la divergenza attesa osservata nei grafici dello studio oracolo di riferimento (Sezione 2.5).

Il $\Delta(Y_{corretta})$ negli altri 7 problemi assume valori prossimi allo zero e anche negativi, indicando una divergenza minima dove talvolta la traiettoria del cluster Y_i si mantiene sopra quella del cluster $\neg Y_i$. Poichè le traiettorie entropiche mostrano il progressivo guadagno di informazione introdotto da ogni passo della traccia, riducendo lo spazio delle soluzioni finali, si osserva come anche il cluster $\neg Y_i$ riduca questo spazio (figura 4.2). Ciò potrebbe essere dovuto al fatto che la risposta sia generata meno frequentemente, pertanto il modello non riesce a distinguere le tracce convergenti da quelle divergenti rispetto ad essa. Una possibile spiegazione è che il percorso inferenziale che giunge a queste risposte sia più generico e dunque meno consolidato nella conoscenza interna del modello.

Inoltre, come riportato nella tabella 4.1, in entrambi i problemi ove $\hat{Y} = Y_{corretta}$ essa è anche quella con maggior numero di occorrenze.

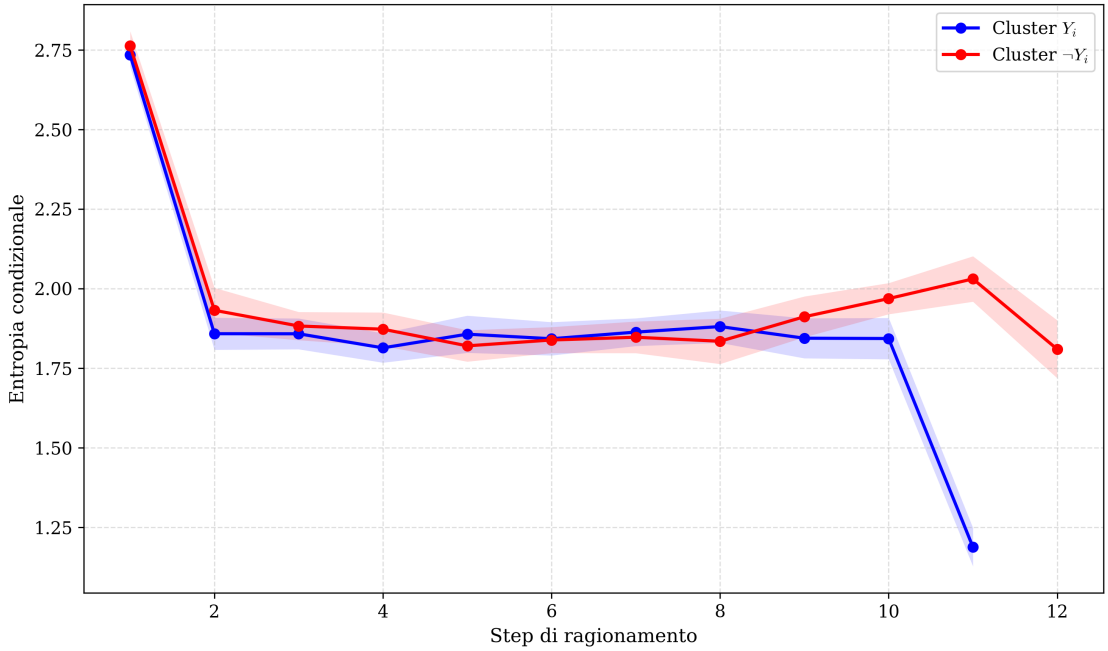

(a) *Int. Algebra* (Liv. 4) #4 - $Y_i = Y_{corretta}(N = 36)$

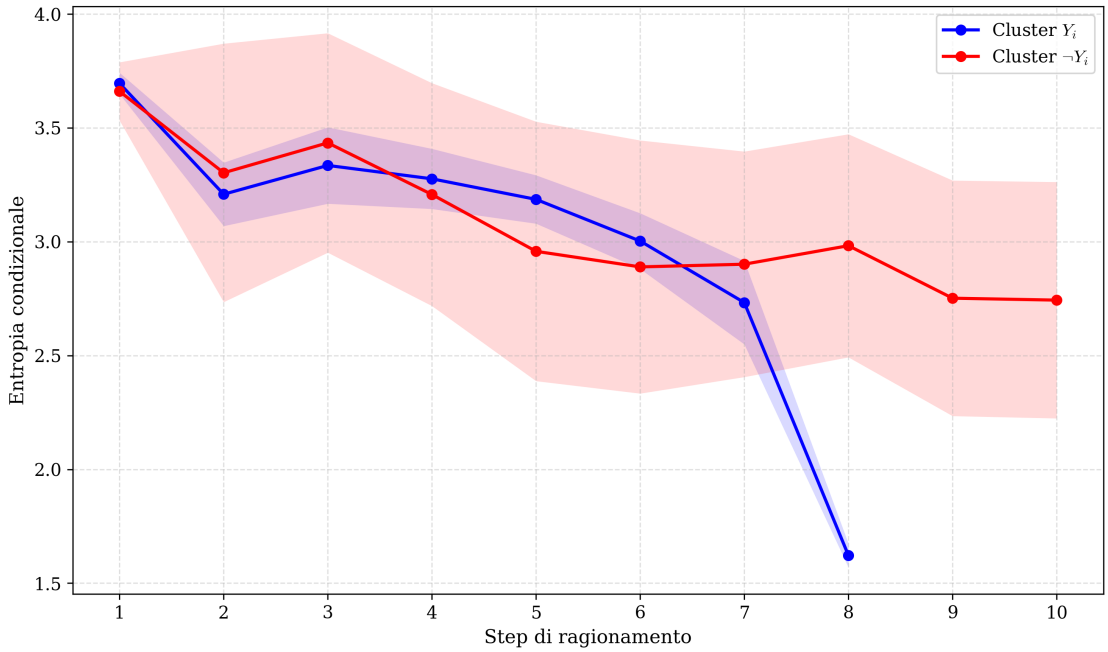

(b) *Int. Algebra* (Liv. 5) #3 - $Y_i = Y_{corretta}(N = 56)$

Figura 4.1: Traiettorie entropiche medie dei cluster con relative bande di incertezza (IC 95,4%). N indica il numero di occorrenze di Y_i.

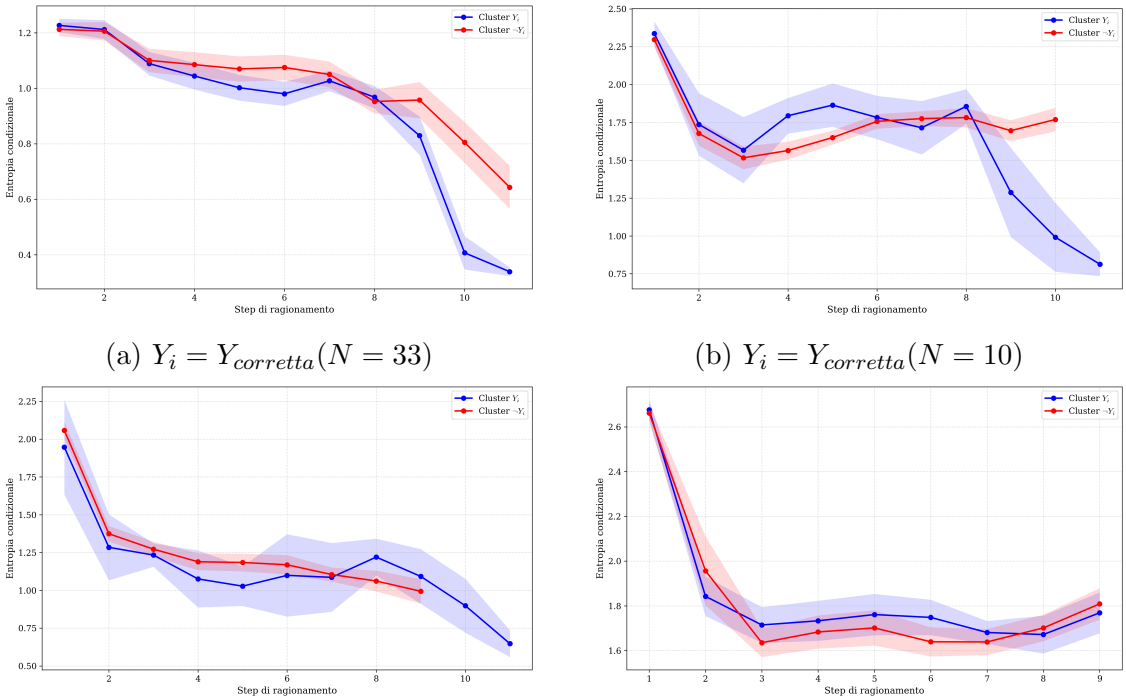

(a) $Y_i = Y_{corretta}(N = 33)$

(b) $Y_i = Y_{corretta}(N = 10)$

(c) $Y_i = Y_{corretta}(N = 4)$

(d) $Y_i = Y_{corretta}(N = 32)$

Figura 4.2: Traiettorie entropiche medie dei cluster con relative bande di incertezza (IC 95,4%) dei problemi *Int. Algebra* (Liv. 4) #3 (a), *Int. Algebra* (Liv. 5) #2 (b), *Int. Algebra* (Liv. 5) #4 (c) e *Int. Algebra* (Liv. 5) #5 (d). N indica il numero di occorrenze di Y_i.

I dati evidenziano invece che un'elevata divergenza caratterizza la risposta con il maggior numero di occorrenze. In 6 problemi su 9 la risposta con maggior numero di occorrenze coincide con $\hat{Y}$, evidenziando una correlazione positiva con la divergenza. Come mostrato in figura 4.3b e 4.3e, nei casi più rappresentativi la divergenza aumenta dopo pochi passi iniziali: il cluster $\neg Y_i$ si mantiene ad entropia elevata, mentre il cluster Y_i mostra un andamento decrescente. Rispetto a queste risposte frequenti, che il modello è incline a generare, la divergenza tra le traiettorie entropiche dei cluster è più marcata; ciò potrebbe significare che il percorso inferenziale dato il problema X, sia ben strutturato e fortemente correlato ad esso nella conoscenza interna del modello.

Utilizzando il criterio (4.2), il comportamento ottenuto è analogo a quello della *Self-Consistency* [13], una tecnica di *test-time scaling* che seleziona tra le risposte generate quella con il maggior numero di occorrenze. In ogni caso, l'uso della divergenza comporta un decremento di accuratezza del 33%, passando dal 55% (*Self-Consistency*) al 22% e richiedendo maggior costo computazionale.

Risposte sintatticamente distinte, seppur matematicamente equivalenti, generano traiettorie entropiche eterogenee. Nella figura 4.4 sono riportate due coppie di grafici, i quali mostrano traiettorie e divergenza differenti per risposte semanticamente identiche. Nello specifico, confrontando le figure 4.4a e 4.4b, si osservano due risposte equivalenti che differiscono unicamente per la notazione: $Y_{corretta} = -\sqrt{2}, -\sqrt{2} + i, -\sqrt{2} - i$ e $Y_{errata2} = -\sqrt{2}, i - \sqrt{2}, -i - \sqrt{2}$. Nonostante l'equivalenza matematica, le traiettorie entropiche risultano significativamente diverse, registrando valori di divergenza opposti ($\Delta(Y_{corretta}) = 0.0940$ contro $\Delta(Y_{errata2}) = -0.1429$). Si riscontra comportamento analogo in 4.4c dove $Y_{corretta} = \frac{1}{2}$ mentre in 4.4d $Y_{errata1} = 0.5$; in questo caso la risposta stima $\hat{Y}$ coincide con la forma decimale $Y_{errata1}$.

Tali evidenze confermano come l'entropia condizionale operi a livello di token e non a livello semantico. È ragionevole dedurre che la massa di probabilità nella generazione della risposta finale sia diluita tra le possibili variazioni sintattiche di un concetto matematico univoco, causando l'osservazione di traiettorie entropiche eterogenee.

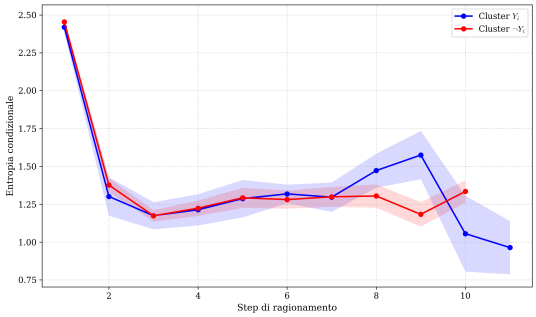

(a) $Y_i = Y_{corretta}(N = 10)$

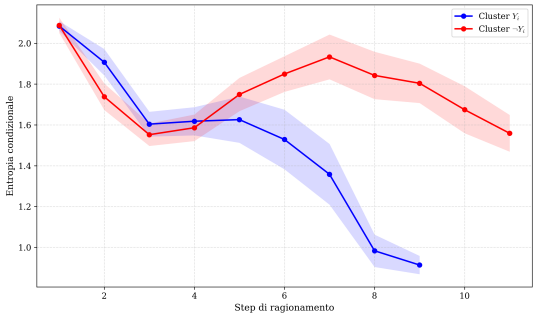

(b) $Y_i = Y_{errata1}(N = 34)$

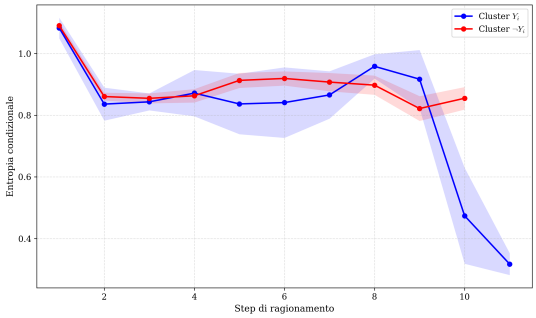

(c) $Y_i = Y_{errata2}(N = 5)$

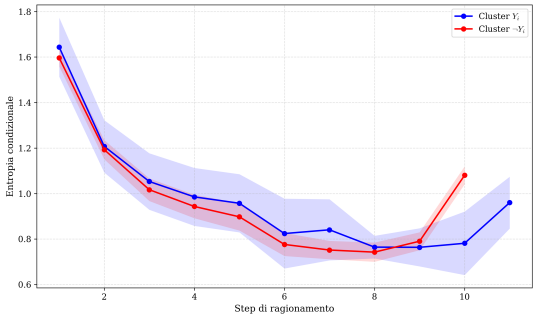

(d) $Y_i = Y_{corretta}(N = 9)$

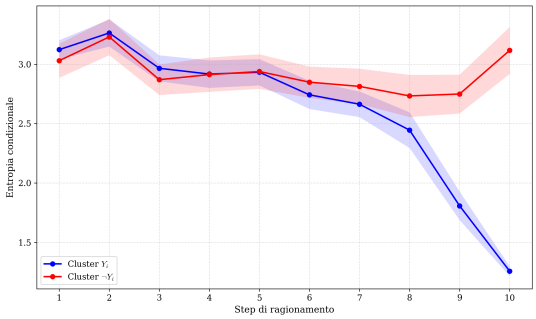

(e) $Y_i = Y_{errata1}(N = 39)$

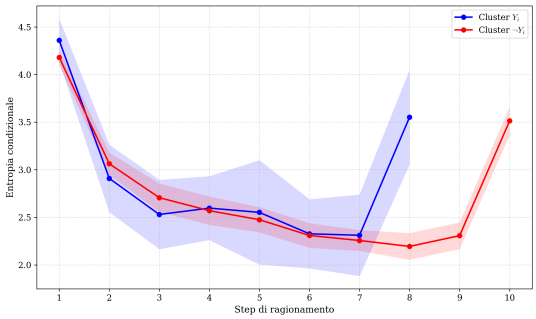

(f) $Y_i = Y_{errata2}(N = 6)$

Figura 4.3: Traiettorie entropiche medie dei cluster con relative bande di incertezza (IC 95,4%) dei problemi *Int. Algebra* (Liv. 4) #2 (a-b-c) e *Int. Algebra* (Liv. 5) #1 (d-e-f). N indica il numero di occorrenze di Y_i.

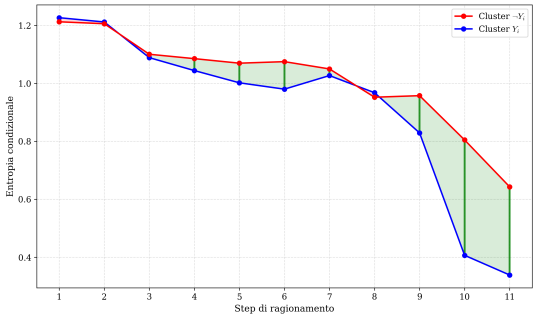

(a) *Int. Algebra* (Liv. 4) #3
$Y_i = Y_{corretta}(N = 33)$

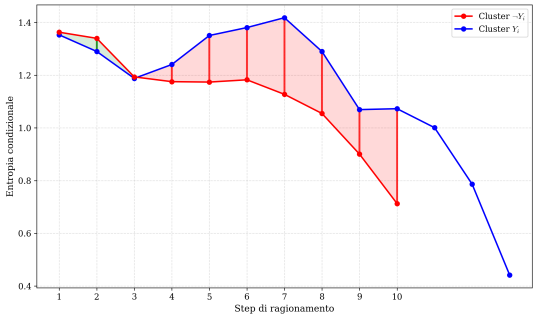

(b) *Int. Algebra* (Liv. 4) #3
$Y_i = Y_{errata2}(N = 7)$

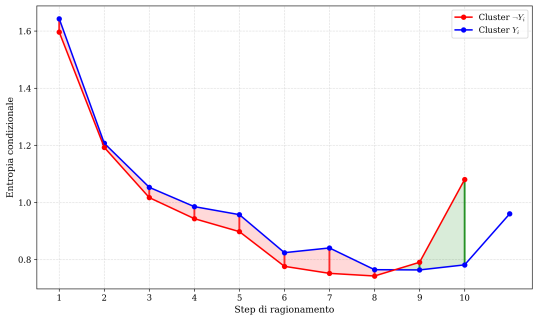

(c) *Int. Algebra* (Liv. 5) #1
$Y_i = Y_{corretta}(N = 9)$

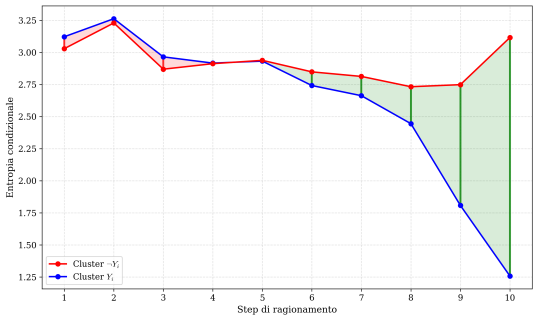

(d) *Int. Algebra* (Liv. 5) #1
$Y_i = Y_{errata1}(N = 39)$

Figura 4.4: Traiettorie entropiche medie dei cluster e rispettive differenze puntuali positive — e negative — . N indica il numero di occorrenze di Y_i.

4.2 Approfondimento sulle singole tracce

Dati i risultati della prima analisi, si è ritenuto necessario un approfondimento sulle traiettorie di entropia condizionale delle singole tracce, in particolare di quelle corrette, evitando elaborazioni aggregate quali media o *resampling* su cluster.

4.2.1 Obiettivo

L'obiettivo di questo approfondimento è analizzare il contenuto semantico dei passi di ragionamento in relazione alla variazione entropica ΔH da essi causata, identificando a quali sequenze di token corrispondano variazioni positive (divergenti rispetto alla risposta finale Y) e a quali corrispondano variazioni negative (convergenti rispetto ad essa).

4.2.2 Elaborazione dati e Criteri

I dati necessari per l'analisi sono stati ottenuti calcolando la traiettoria di entropia condizionale di tracce corrette ($Y_i = Y_{corretta}$) generate rispetto a vari problemi matematici.

Dato il problema X sia $Z = (Z_1, Z_2, \ldots, Z_N)$ la sequenza di passi di ragionamento che giunge alla risposta Y.

La metrica associata ad ogni passo è la variazione entropica, calcolata nel seguente modo per il passo k-esimo:

$$\Delta H_k = H(Y \mid X, Z_{\leq k}) - H(Y \mid X, Z_{\leq k-1}) \quad \text{con} \quad Z_k \in [1, N] \tag{4.3}$$

Dunque un $\Delta H_k > 0$ indica che il passo k-esimo ha incrementato l'incertezza media nella generazione della risposta Y, aumentando lo spazio di possibili risposte finali, viceversa un $\Delta H_k < 0$ lo riduce.

Definizione di passo divergente. Un passo di ragionamento Z_k è definito divergente se presenta una variazione entropica $\Delta H_k > 0$.

Definizione di passo convergente. Un passo di ragionamento Z_k è definito convergente se presenta una variazione entropica $\Delta H_k \leq 0$.

Definizione di minimo locale. Si definisce minimo locale un passo convergente Z_k che segna la fine di una fase di riduzione di incertezza. Un passo Z_k è un minimo locale se è seguito da un passo divergente, oppure se è l'ultimo passo della traccia ($k = N$).

Definizione di ciclo. Sia $\mathcal{M} = \{m_0, m_1, \ldots, m_P\}$ l'insieme ordinato degli indici corrispondenti ai minimi locali identificati nella traccia, ponendo per convenzione $m_0 = 0$. Un ciclo C_i è definito come la sottosequenza di passi compresa tra due minimi locali consecutivi:

$$C_i = \{Z_k \mid m_{i-1} < k \leq m_i\} \quad \text{con} \quad 1 \leq i \leq P \tag{4.4}$$

4.2.3 Risultati e Discussione

L'approfondimento è stato condotto su un numero esteso di singole tracce. In questa sezione se ne riportano i casi studio rappresentativi, scelti per sostenere le osservazioni emerse dallo studio complessivo.

I dati sono organizzati in tabelle che riportano, per ogni passo di ragionamento, il contenuto testuale generato dal modello Z_k e la relativa variazione di entropia condizionale ΔH_k (Eq. 4.3). Viene inoltre proposta una segmentazione delle tracce in cicli di ragionamento, identificando come passi divergenti esclusivamente quelli caratterizzati da un incremento netto dell'entropia ($\Delta H_k \gg 0$), così da focalizzarsi su variazioni entropiche significative e mettere in risalto le peculiarità dei passi divergenti. Questa metodologia permette la visualizzazione diretta delle fasi di espansione e contrazione dello spazio delle soluzioni finali nell'evoluzione di una traccia di ragionamento.

Le traiettorie entropiche non decrescono linearmente. L'analisi delle singole tracce di ragionamento rivela che la tendenza decrescente dell'entropia condizionale non è monotona lineare, come appare dai dati aggregati su cluster dello studio oracolo [2], bensì ciclica.

Ogni ciclo (Eq. 4.4) è caratterizzato da una fase iniziale di divergenza, dove l'entropia aumenta rispetto al passo precedente, seguita da una fase di convergenza; esso si conclude spesso con un'entropia inferiore rispetto a quella iniziale, costituendo un incremento di informazione mutua condizionale (Sezione 2.5).

Questo andamento suggerisce che, nel paradigma *Chain-of-Thought* (Sezione 2.3), siano necessari passi che traslano temporaneamente il focus predittivo del modello dalla risposta finale (Y) verso elaborazioni intermedie. Sebbene questi passi incrementino l'incertezza sulla generazione della risposta finale, essi sono funzionali alla scomposizione della complessità del problema originale.

L'analogia osservabile è quella tra la risoluzione mentale e quella scritta. Risolvere un problema complesso tenendo a mente variabili, concetti matematici e risultati intermedi richiede un notevole carico cognitivo; la scrittura, d'altro canto, semplifica il processo poiché, riducendo il carico cognitivo dovuto alla memorizzazione, consente di focalizzarsi sull'elaborazione dei dati [14]. L'esplicitazione di dati intermedi, non direttamente correlati alla risposta finale, consente al modello di focalizzarsi sulla loro elaborazione nei passi successivi; tale processo è descritto dall'andamento non lineare dell'entropia.

Problema: *Int. Algebra* (Liv. 5) #3

Let m be a positive integer, and let $a_0, a_1, \ldots, a_m$ be a sequence of real numbers such that $a_0 = 37$, $a_1 = 72$, $a_m = 0$, and

$$a_{k+1} = a_{k-1} - \frac{3}{a_k}$$

for $k = 1, 2, \ldots, m-1$. Find m.

Tabella 4.2: Analisi della variazione entropica ΔH del problema sopra riportato.

Passi di Ragionamento	ΔH
Step 1: We start with the given recursive relation for the sequence: $a_{k+1} = a_{k-1} - \frac{3}{a_k}$ for $k = 1, 2, \ldots, m-1$.	
Step 2: To find a pattern or useful transformation, we multiply both sides of the recursive relation by a_k: $a_k a_{k+1} = a_k a_{k-1} - 3$	-1.36
Step 3: Let us define a new sequence $b_k = a_k a_{k-1}$. Then, the equation becomes: $b_{k+1} = b_k - 3$	+1.28
Step 4: Since this is an arithmetic sequence with common difference -3, we have: $b_{k+1} = b_1 - 3k$	-0.39
Step 5: We know $b_1 = a_1 a_0$. Given $a_0 = 37$ and $a_1 = 72$, we find: $b_1 = 37 \cdot 72 = 2664$	+0.06
Step 6: Thus, the general term of the sequence b_k can be written as: $b_{k+1} = 2664 - 3k$	-0.06
Step 7: For b_m to be zero (since $a_m = 0$), we set $b_m = 0$: $2664 - 3(m-1) = 0$	-0.05
Step 8: Solving for m: $2664 - 3m + 3 = 0$ $2667 - 3m = 0$ $3m = 2667$ $m = \frac{2667}{3} = 889$	-1.96

Nota: L'alternanza di bande (bianco/grigio) evidenzia i cicli.

I passi divergenti costituiscono l'impalcatura del ragionamento. L'incremento di entropia ($\Delta H_k > 0$) (Eq. 4.3) riflette il fatto che un contesto C, esteso da un passo divergente Z_k, non è direttamente predittivo rispetto alla risposta finale, segnalando la necessità di ulteriore elaborazione dello stato del problema. I token introdotti in questi passi determinano un "appiattimento" delle distribuzioni di probabilità sui token della risposta finale: essi rappresentano sequenze più astratte che, pur non aggiungendo informazione immediata sulla soluzione specifica, costituiscono prerequisiti indispensabili per abilitare le successive inferenze convergenti. È possibile interpretare il passo divergente come un'impalcatura: una struttura che espande temporaneamente lo spazio delle possibilità percorribili, necessaria per sostenere la complessità del ragionamento prima che esso possa convergere nuovamente verso la soluzione.

Dall'analisi qualitativa delle tracce rappresentative, si possono individuare due tipologie di passi divergenti:

- **Astrazione e Pianificazione**: Come evidenziato nella Tabella 4.2 (Step 3), la definizione di una nuova successione ausiliaria (b_k) comporta un picco entropico significativo ($\Delta H = +1.28$). Analogamente, nella Tabella 4.3 (Step 6), l'entropia aumenta moderatamente (+0.16) quando il modello imposta la derivata a zero; l'equazione risultante non è direttamente predittiva della risposta finale, ma definisce un obiettivo intermedio necessario. Similmente, negli Step 5-6 della Tabella 4.4, la chiusura di un vincolo parziale ($f < 2$) e l'apertura del successivo aumentano l'incertezza (+0.36), segnalando l'incompletezza della risoluzione del problema iniziale.
- **Sviluppo algebrico**: Nella Tabella 4.3, gli Step 8-10 mostrano come la manipolazione algebrica pura (espansione di quadrati, moltiplicazione membro a membro) generi entropia positiva ($+0.45, +0.18$); l'introduzione di numerosi termini algebrici allontana momentaneamente lo stato del problema dalla forma della risposta finale.

In conclusione, è ragionevole dedurre che i passi divergenti siano funzionali alla gestione della complessità: essi spostano temporaneamente il focus dalla generazione della risposta finale all'elaborazione di risultati intermedi, abilitando la risoluzione sequenziale del problema.

Problema: *Int. Algebra* (Liv. 4) #2

Find the minimum value of

$$\sqrt{x^2 + (1-x)^2} + \sqrt{(1-x)^2 + (1+x)^2}$$

over all real numbers x.

Tabella 4.3: Analisi della variazione entropica ΔH del problema sopra riportato.

Passi di Ragionamento	ΔH
Step 1: Define the function we need to minimize: $f(x) = \sqrt{x^2 + (1-x)^2} + \sqrt{(1-x)^2 + (1+x)^2}$	
Step 2: Simplify each term within the function separately: $f(x) = \sqrt{x^2 + 1 - 2x + x^2} + \sqrt{1 - 2x + x^2 + 1 + 2x + x^2}$	-1.18
Step 3: Combine like terms under each square root: $f(x) = \sqrt{2x^2 - 2x + 1} + \sqrt{2x^2 + 2}$	+0.08
Step 4: To find the critical points, compute the derivative of $f(x)$: $f'(x) = \frac{d}{dx}\left(\sqrt{2x^2 - 2x + 1}\right) + \frac{d}{dx}\left(\sqrt{2x^2 + 2}\right)$	-0.38
Step 5: Apply the chain rule to each term: $f'(x) = \frac{1}{2\sqrt{2x^2 - 2x + 1}} \cdot (4x - 2) + \frac{1}{2\sqrt{2x^2 + 2}} \cdot 4x$ $f'(x) = \frac{4x - 2}{2\sqrt{2x^2 - 2x + 1}} + \frac{4x}{2\sqrt{2x^2 + 2}}$ $f'(x) = \frac{2x - 1}{\sqrt{2x^2 - 2x + 1}} + \frac{2x}{\sqrt{2x^2 + 2}}$	+0.02
Step 6: Set the derivative equal to zero to find the critical points: $\frac{2x - 1}{\sqrt{2x^2 - 2x + 1}} + \frac{2x}{\sqrt{2x^2 + 2}} = 0$	+0.16
Step 7: Solve for x by isolating one of the fractions: $\frac{2x - 1}{\sqrt{2x^2 - 2x + 1}} = -\frac{2x}{\sqrt{2x^2 + 2}}$	-0.30
Step 8: Cross-multiply to clear the denominators: $(2x - 1)\sqrt{2x^2 + 2} = -2x\sqrt{2x^2 - 2x + 1}$	+0.45

Tabella 4.3: ΔH - Problema: *Int. Algebra* (Liv. 4) #2 (continua)

Passi di Ragionamento	ΔH
Step 9: Square both sides to eliminate the square roots: $(2x-1)^2(2x^2+2) = (-2x)^2(2x^2-2x+1)$ $(4x^2-4x+1)(2x^2+2) = 4x^2(2x^2-2x+1)$	+0.16
Step 10: Expand both sides: $8x^4 - 8x^3 + 2x^2 + 8x^2 - 8x + 2 = 8x^4 - 8x^3 + 4x^2$	+0.18
Step 11: Simplify and combine like terms: $10x^2 - 8x + 2 = 4x^2$ $6x^2 - 8x + 2 = 0$	-0.07
Step 12: Divide through by 2 to simplify: $3x^2 - 4x + 1 = 0$	+0.08
Step 13: Solve the quadratic equation using the quadratic formula $x = \frac{-b \pm \sqrt{b^2-4ac}}{2a}$, where $a = 3$, $b = -4$, and $c = 1$: $x = \dfrac{-(-4) \pm \sqrt{(-4)^2 - 4 \cdot 3 \cdot 1}}{2 \cdot 3}$ $x = \dfrac{4 \pm \sqrt{16-12}}{6}$ $x = \dfrac{4 \pm 2}{6}$ $x = 1 \quad \text{or} \quad x = \dfrac{1}{3}$	-0.44
Step 14: Evaluate $f(x)$ at the critical points $x = 1$ and $x = \frac{1}{3}$: - At $x = 1$: $f(1) = \sqrt{1^2 + (1-1)^2} + \sqrt{(1-1)^2 + (1+1)^2} = \sqrt{1+0} + \sqrt{0+4} = 1 + 2 = 3$ - At $x = \frac{1}{3}$: $f\left(\dfrac{1}{3}\right) = \sqrt{\left(\dfrac{1}{3}\right)^2 + \left(\dfrac{2}{3}\right)^2} + \sqrt{\left(\dfrac{2}{3}\right)^2 + \left(\dfrac{4}{3}\right)^2}$ $= \sqrt{\dfrac{1}{9} + \dfrac{4}{9}} + \sqrt{\dfrac{4}{9} + \dfrac{16}{9}} = \sqrt{\dfrac{5}{9}} + \sqrt{\dfrac{20}{9}} = \dfrac{\sqrt{5}}{3} + \dfrac{2\sqrt{5}}{3} = \sqrt{5}$	-0.63
Step 15: Determine the smaller value between these two results: The minimum value is $\sqrt{5}$.	+0.28

Nota: L'alternanza di bande (bianco/grigio) evidenzia i cicli.

I passi convergenti costituiscono l'elaborazione del contesto. L'analisi dei passi a variazione entropica negativa ($\Delta H < 0$) (Eq. 4.3) caratterizza la fase di inferenza convergente. In questa fase, lo spazio delle soluzioni ammissibili si riduce drasticamente: i token generati impongono vincoli rigidi che "collassano" l'incertezza nella generazione della soluzione finale Y.

A differenza dei passi divergenti, i passi convergenti elaborano il contesto esistente per estrarne informazione diretta su Y. Le funzioni principali svolte da questi passi sono:

- **Impostazione iniziale**: Come evidenziato nello Step 2 delle Tabelle 4.4 e 4.2, si registra spesso una significativa riduzione entropica nei primi passi di ragionamento. L'introduzione di questi token restringe il vasto spazio di ricerca iniziale, selezionando un percorso inferenziale fortemente correlato alla risposta ed escludendo a priori ampie porzioni di soluzioni incompatibili.
- **Risoluzione e Calcolo**: Negli Step 13-14 (4.3) o 11-12 (4.4), la convergenza deriva da inferenze di calcolo fondate sul contesto precedente. Tramite semplificazioni o risultati intermedi, il focus del modello si riallinea direttamente alla generazione della risposta finale.

In conclusione, tali passi introducono esplicitamente vincoli nel contesto C, tramite esecuzione di calcoli oppure impostazione della risoluzione, così da escludere risposte incompatibili e restringere lo spazio di possibili soluzioni.

Problema: *Int. Algebra* (Liv. 5) #5

Let x, y, z be positive real numbers. Find the set of all possible values of

$$f(x,y,z) = \frac{x}{x+y} + \frac{y}{y+z} + \frac{z}{z+x}.$$

Tabella 4.4: Analisi della variazione entropica ΔH del problema sopra riportato.

Passi di Ragionamento	ΔH
Step 1: Consider the function $f(x,y,z) = \frac{x}{x+y} + \frac{y}{y+z} + \frac{z}{z+x}$, where x, y, z are positive real numbers.	

Tabella 4.4: ΔH - Problema: *Int. Algebra* (Liv. 5) #5 (continua)

Passi di Ragionamento	ΔH
Step 2: First, we show that $f(x,y,z) < 2$. We start with the inequality for each fraction: $\frac{x}{x+y} < \frac{x+z}{x+y+z}$, since adding z to both numerator and denominator increases the value.	-0.81
Step 3: Similarly, $\frac{y}{y+z} < \frac{y+x}{y+z+x}$, and $\frac{z}{z+x} < \frac{z+y}{z+x+y}$.	-0.09
Step 4: Adding these inequalities gives us: $\frac{x}{x+y} + \frac{y}{y+z} + \frac{z}{z+x} < \frac{x+z}{x+y+z} + \frac{y+x}{y+z+x} + \frac{z+y}{z+x+y}$.	-0.34
Step 5: Simplifying the right side, we obtain: $\frac{x+z}{x+y+z} + \frac{y+x}{y+z+x} + \frac{z+y}{z+x+y} = 2$.	+0.15
Step 6: Thus, we have shown that $f(x,y,z) < 2$.	+0.36
Step 7: Next, we prove that $f(x,y,z) > 1$. Consider: $\frac{x}{x+y} > \frac{x}{x+y+z}$.	-0.02
Step 8: Similarly, $\frac{y}{y+z} > \frac{y}{x+y+z}$, $\frac{z}{z+x} > \frac{z}{x+y+z}$.	-0.05
Step 9: Adding these inequalities gives us: Sum $> \frac{x+y+z}{x+y+z}$.	-0.01
Step 10: Simplifying the right side, we obtain 1.	+0.09
Step 11: Thus, we have shown that $f(x,y,z) > 1$.	-0.16
Step 12: Finally, we determine the range: $1 < f(x,y,z) < 2$.	-0.17

Nota: L'alternanza di bande (bianco/grigio) evidenzia i cicli.

Capitolo 5

Conclusioni

Il presente lavoro di tesi trae origine dalla necessità di individuare una metrica interna al modello e agnostica al dominio, in grado di fungere da euristica valida per guidare il ragionamento. A tal fine, si è adottata l'entropia condizionale per valutare l'utilità dei passi di ragionamento, verificando l'ipotesi secondo cui la divergenza, tra le traiettorie entropiche medie dei cluster di tracce, sia correlata alla correttezza della risposta.

Tuttavia, i risultati sperimentali non supportano l'ipotesi che la divergenza sia un *proxy* diretto della correttezza. Dall'analisi emerge infatti che la divergenza dei cluster rispetto alla risposta corretta è generalmente prossima allo zero, ad eccezione dei casi in cui coincide con la più frequente. La divergenza media risulta significativamente più alta proprio rispetto alla risposta generata più frequentemente. Pertanto, mentre il modello distingue nettamente l'andamento dell'incertezza per la risposta più frequente, tale capacità discriminante non emerge per le altre risposte. Ne consegue la necessità di indagare più a fondo il legame tra divergenza e frequenza di generazione delle risposte. Inoltre, l'osservazione di risposte sintatticamente distinte, seppur matematicamente equivalenti, che generano traiettorie entropiche eterogenee suggerisce come, la massa di probabilità nella generazione della risposta finale, sia diluita tra le possibili variazioni sintattiche.

L'approfondimento sulle singole tracce ha rivelato che il ragionamento corretto non segue un decremento monotono dell'incertezza. Al contrario, l'andamento dell'entropia condizionale non appare lineare, bensì ciclico, dove ogni ciclo è caratterizzato da una fase iniziale di divergenza, seguita da una fase di convergenza rispetto alla risposta finale. I passi divergenti possono essere interpretati come un' 'impalcatura': essi traslano temporaneamente il focus predittivo del modello dalla risposta finale verso elaborazioni intermedie, aumentando momentaneamente l'incertezza ma abilitando le successive inferenze convergenti. I passi convergenti, infatti, concretizzano l'elaborazione del contesto tramite token che impongono vincoli rigidi sulla soluzione finale, determinando così il "collasso" dell'incertezza nella sua generazione.

Limitazioni e Sviluppi futuri. Le limitazioni dello studio risiedono nella specificità del dominio matematico analizzato (dataset MATH) e dei modelli utilizzati; tali fattori non garantiscono a priori la generalizzabilità dei risultati ad altri contesti. Allo stesso modo, vincoli in termini di risorse hanno circoscritto l'indagine sperimentale a un campione ristretto di problemi. Inoltre, è doveroso precisare che la metodologia adottata si configura come un'analisi empirica a posteriori: l'uso del *teacher forcing* è stato necessario per validare l'ipotesi della divergenza su traiettorie complete. Sebbene tale approccio sia replicabile in fase di inferenza (es. tramite *rollout* MCTS), esso comporta un costo computazionale che ne limita l'impiego in contesti reali. Pertanto, trovare un segnale interno efficiente che guidi il ragionamento resta una sfida aperta; in tal senso, le future direzioni di ricerca potrebbero orientarsi verso l'identificazione di nuovi pattern all'interno delle traiettorie entropiche, o verso l'adozione di metriche intrinseche differenti per la definizione delle traiettorie stesse.

In quest'ottica, l'obiettivo principale è quello di approfondire la relazione tra la divergenza e la frequenza di generazione di una risposta, utilizzando anche altri tipi di entropia come quella semantica, che riflette l'incertezza "concettuale" del modello. Tale approccio permetterebbe di isolare meglio l'entropia aleatoria, dovuta al 'come' rendere una risposta, e di stimare quella epistemica, dovuta all'effettiva mancanza di conoscenza del modello. Rimanendo nell'ottica semantica, uno studio sulle rappresentazioni interne potrebbe rivelare varie informazioni su come vengano gestiti internamente i concetti, consentendo di osservare meglio le dinamiche di ragionamento di questi modelli. Tuttavia, le evidenze emerse rappresentano una base valida per future ricerche sull'interpretabilità degli LLM.

Citando Yann LeCun, uno dei padri fondatori del *deep learning*:

"The interesting thing about deep learning is that it's an engineering artifact that we need to study and that we don't completely understand... a lot of artifacts like the telescope, the steam engine, electromagnets, you know, the airplane etc have appeared before people actually had the theory to explain how they work." [15].

Appendice A

Analisi statistica

La presente appendice riporta le definizioni delle metriche statistiche, adottate per la valutazione dell'affidabilità delle traiettorie medie presentate nei grafici.

Deviazione standard campionaria La deviazione standard (o scarto quadratico medio) costituisce la misura fondamentale della dispersione dei dati attorno al valore atteso. Operando su un sottoinsieme finito di osservazioni (campione), per stimare i parametri dell'intera popolazione si fa riferimento alla *deviazione standard campionaria* s. A differenza della deviazione standard della popolazione σ, la formulazione campionaria applica la correzione di Bessel al denominatore ($N-1$ anziché N), al fine di fornire una stima non distorta della varianza della popolazione. Data una variabile aleatoria x misurata su un campione di dimensione N, con media campionaria $\bar{x}$, la deviazione standard è definita come:

$$s = \sqrt{\frac{1}{N-1}\sum_{i=1}^{N}(x_i - \bar{x})^2}$$

Errore standard Mentre la deviazione standard quantifica la dispersione dei singoli dati, l'errore standard $s_{\bar{x}}$ misura l'incertezza associata alla stima della media stessa. Esso esprime la deviazione tra la media campionaria calcolata $\bar{x}$ e la media reale della popolazione μ. L'errore standard è derivato dalla deviazione standard campionaria e dalla numerosità del campione secondo la relazione:

$$s_{\bar{x}} = \frac{s}{\sqrt{N}}$$

Intervallo di confidenza L'Intervallo di Confidenza (IC) definisce un intervallo di valori entro il quale si stima che ricada la media reale della popolazione μ con una specifica probabilità. Operativamente, tale intervallo è centrato sulla media campionaria $\bar{x}$ e la sua ampiezza è determinata dal prodotto tra l'errore standard ($s_{\bar{x}}$) e un fattore di copertura k:

$$IC = \bar{x} \pm (k \cdot s_{\bar{x}})$$

Il fattore k determina il livello di probabilità desiderato, assumendo che la distribuzione delle medie campionarie approssimi una distribuzione normale (Teorema del Limite Centrale). È tuttavia necessario notare che tale approssimazione è asintotica, ovvero diviene sempre più accurata al crescere della numerosità campionaria. In presenza di campioni ridotti, la convergenza verso la normale è meno efficace e l'uso di un fattore fisso può indurre una sottostima dell'incertezza reale. Nel presente contesto è stato adottato un fattore di copertura $k = 2$. Tale scelta definisce un intervallo che, assumendo valida l'ipotesi di normalità, offre una confidenza del 95.4% di contenere la media reale della popolazione.

Appendice B

Splines cubiche

Data una sequenza di $n+1$ punti (nodi) (x_i, y_i) con $x_0 < x_1 < \cdots < x_n$, si definisce spline cubica interpolante una funzione $S(x)$ continua a tratti che soddisfa le seguenti proprietà:

- In ogni sotto-intervallo $[x_i, x_{i+1}]$ (per $i = 0, \ldots, n-1$), la funzione coincide con un polinomio di terzo grado:

$$S_i(x) = a_i + b_i(x - x_i) + c_i(x - x_i)^2 + d_i(x - x_i)^3$$

- La funzione soddisfa la condizione di interpolazione, passando esattamente per tutti i nodi della sequenza originale:

$$S(x_i) = y_i \quad \text{per } i = 0, \ldots, n$$

- La funzione $S(x)$, la sua derivata prima $S'(x)$ e la sua derivata seconda $S''(x)$ sono continue su tutto l'intervallo di definizione. Tale regolarità (C^2) garantisce l'assenza di punti angolosi e variazioni brusche di curvatura nei punti di giunzione.

L'interpolazione tramite spline cubiche è lo strumento matematico che permette di trasformare una sequenza discreta di lunghezza arbitraria in una funzione continua. Questa proprietà è fondamentale quando si devono confrontare sequenze composte da un numero diverso di punti: la spline permette di svincolarsi dalla discretizzazione originale e di ricampionare le curve su un dominio comune (normalizzato).

Inoltre, la spline cubica naturale gode della proprietà di *minima energia*: tra tutte le funzioni interpolanti di classe C^2, è quella che minimizza la curvatura globale, assicurando così la minor distorsione possibile del trend dei dati.

Bibliografia

[1] D. Kahneman, *Thinking, Fast and Slow.* New York: Farrar, Straus and Giroux, 2011.

[2] X. Guo, "Measuring reasoning utility in llms via conditional entropy reduction," 2025.

[3] W. X. Zhao, K. Zhou, J. Li, T. Tang, X. Wang, Y. Hou, Y. Min, B. Zhang, J. Zhang, Z. Dong, Y. Du, C. Yang, Y. Chen, Z. Chen, J. Jiang, R. Ren, Y. Li, X. Tang, Z. Liu, P. Liu, J.-Y. Nie, and J.-R. Wen, "A survey of large language models," 2025.

[4] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning.* MIT Press, 2016. Sequence Modeling: Recurrent and Recursive Nets.

[5] Z.-Z. Li, D. Zhang, M.-L. Zhang, J. Zhang, Z. Liu, Y. Yao, H. Xu, J. Zheng, P.-J. Wang, X. Chen, Y. Zhang, F. Yin, J. Dong, Z. Li, B.-L. Bi, L.-R. Mei, J. Fang, X. Liang, Z. Guo, L. Song, and C.-L. Liu, "From system 1 to system 2: A survey of reasoning large language models," 2025.

[6] J. Wei, X. Wang, D. Schuurmans, M. Bosma, B. Ichter, F. Xia, E. Chi, Q. Le, and D. Zhou, "Chain-of-thought prompting elicits reasoning in large language models," 2023.

[7] T. Kojima, S. S. Gu, M. Reid, Y. Matsuo, and Y. Iwasawa, "Large language models are zero-shot reasoners," 2023.

[8] S. Dutta, J. Singh, S. Chakrabarti, and T. Chakraborty, "How to think step-by-step: A mechanistic understanding of chain-of-thought reasoning," 2024.

[9] T. M. Cover and J. A. Thomas, *Elements of Information Theory.* Hoboken, NJ: Wiley-Interscience, 2 ed., 2006.

[10] C. E. Shannon, "A mathematical theory of communication," *The Bell System Technical Journal*, vol. 27, no. 3, pp. 379–423, 1948.

[11] D. Hendrycks, C. Burns, S. Kadavath, A. Arora, S. Basart, E. Tang, D. Song, and J. Steinhardt, "Measuring mathematical problem solving with the math dataset," 2021.

[12] Modal, Inc., "Modal: The Unified Platform for AI and Data." `https://modal.com`, [2025]. Piattaforma utilizzata nel corso del 2025.

[13] X. Wang, J. Wei, D. Schuurmans, Q. Le, E. Chi, S. Narang, A. Chowdhery, and D. Zhou, "Self-consistency improves chain of thought reasoning in language models," 2023.

[14] M. Nye, A. J. Andreassen, G. Gur-Ari, H. Michalewski, J. Austin, D. Bieber, D. Dohan, A. Lewkowycz, M. Bosma, D. Luan, C. Sutton, and A. Odena, "Show your work: Scratchpads for intermediate computation with language models," 2021.

[15] Y. LeCun, "Deep learning hardware: Past, present, and future," in *2019 IEEE International Solid-State Circuits Conference - (ISSCC)*, (San Francisco, CA, USA), pp. 12–19, IEEE, Feb 2019.

Ringraziamenti

In totale onestà non so da dove iniziare, non sono bravo con le parole ma spero che le frasi rendano quanto le abbia scritte con il cuore.

Ringrazio il Prof. Bria, per avermi assistito nella concretizzazione di questo lavoro, che rischiava di perdersi tra le numerose vie percorribili nella ricerca attuale. È grazie a questa tesi se ho la certezza di approfondire i miei studi nell'ambito dell'intelligenza artificiale.

Ringrazio Mamma, Papà e Alessandra, per non avermi mai fatto mancare nulla rendendo tutto ciò possibile. Voglio dedicare a voi questo traguardo, non c'è cosa che mi renda più contento di quanto siate orgogliosi di me, siete la mia costante in una vita di incertezze. Un pensiero a Mamma e Ale, grazie per aver organizzato interamente la festa ed il resto, sacrificando il vostro tempo, senza di voi non ci sarei riuscito.

Ringrazio Nonno Pietro, è grazie alle giornate passate insieme su mezzi di ogni tipo che ho sviluppato l'esigenza di capire come funzionassero. Certo, non avrò approfondito la meccanica, ma quella curiosità mi accompagnerà sempre.

Ringrazio la mia famiglia, per credere in me da quando sono piccolo. Anche se non riusciamo a vederci spesso, il mio pensiero va a tutti voi.

Ringrazio Francesco e Raffaele, siete fratelli per me e lo sarete per sempre. Voi più di tutti sapete le difficoltà ma anche le soddisfazioni che ho vissuto non solo in questo percorso, ma anche negli anni. Grazie per essermi vicini e credere in me, vi voglio un mondo di bene.

Ringrazio Alfredo e Vincenzo, sembra l'altro giorno che abbiamo creato il gruppo di lavoro, tra CdA in atrio e ping pong alla fine ci siamo laureati tutti. Ci lasciamo alle spalle momenti indelebili, ma soprattutto la sensazione che questi tre anni ce li siamo goduti a pieno, rifarei tutto tornassi indietro.

Ringrazio Andrea, fedele compagno di podcast, per tutte le risate fatte assieme. Hai coniato l' "ehy piiit", icona del nostro primo anno, sei sempre stato disponibile, ti auguro il meglio per tutto.

Ringrazio Pierpaolo, Luigi e Simone, quelle lezioni di circuiti hanno dato inizio all'apocalisse. Uniti al gruppo di lavoro, credo che questa università non abbia visto gruppo con meno contegno di noi, e non posso che esserne fiero.

Ringrazio Mirko, Mattia, Biagio, Francesco e Armando per aver fatto parte di una baracca già instabile di suo, rendendola incontrollabile in modo definitivo. Grazie per esserci stati.

Ringrazio Manuel, hai sempre aiutato tutti compreso me, sei una grande persona. Non scorderò mai i momenti vissuti insieme, soprattutto l'orangotango, ti voglio bene.

Ringrazio Andrea, Leonardo, Paolo, Gianmarco, Salvo e Samuele, per esserci da svariati anni, anche se a distanza. Vengono i brividi a ripensare a quando ci siamo conosciuti, spero davvero tanto che riusciremo in futuro ad abbattere le distanze come abbiamo fatto di recente, non appena ci è stato possibile. Siete la testimonianza di quanto sia semplice costruire amicizie genuine con le persone giuste.

Ringrazio me stesso, per aver avverato il semplice desiderio di comprendere come funzionasse un PC a partire da una presa elettrica. Lascio questo messaggio al me del futuro: che questo sia il primissimo dei traguardi che raggiungerai Pietro, che il risultato sia sempre una conseguenza e non un fine, nessun problema è irrisolvibile, basta solo comprenderlo.